

AI Bot — Safety Policy

Политика безопасности и
ограничения контента
DOC-04 / v1.0 / Backend Architecture
Package

1. Назначение документа

Данный документ определяет правила работы Safety Layer — модуля проверки, который выполняется перед каждым ответом бота при наличии потенциально чувствительного контента. Бот работает в области beauty, wellness и питания, что создаёт пересечение с медицинскими темами.

△ Safety Layer — это **не промпт-фильтр**, а программный модуль с детерминированными правилами. Часть правил применяется до LLM, часть — после генерации ответа.

2. Классификация рисков

Каждое входящее сообщение получает оценку risk_level, которая определяет поведение системы:

risk_level	Признаки	Поведение системы
LOW	Обычный запрос об услуге, цене, расписании, визитной карте	Отвечает на запрос, модуль Safety Layer не выполняет проверку
MEDIUM	Упомянуты: беременность, варикоз, диабет, тонус, оплодотворение	Детерминированный ответ, не выдаёт рекомендаций
HIGH	Боль, воспаление, открытые раны, онкология	Немедленно передаёт модерации, блокирует дальнейшее взаимодействие

3. Запрещённые формулировки (Hard Rules)

Следующие формулировки **категорически запрещены** в ответах бота. После генерации ответа LLM выполняется автоматическая проверка на наличие этих паттернов. При обнаружении ответ блокируется и заменяется безопасным шаблоном.

Категория	Запрещённые паттерны
Гарантии результата	«похудеете на X кг», «гарантируем результат», «100% эффект», «точно поможет»
Медицинские заявления	«лечит», «вылечим», «устранит заболевание», «терапевтический эффект», «медицинский эффект»
Диагностика	«у вас, скорее всего», «это симптомы», «похоже на», «диагноз», «анализы покажут»
Назначения	«принимайте», «пейте», «нужно сдать анализы», «обратитесь к врачу [конкретному]»
Сравнение с медициной	«аналог лечения», «заменяет операцию», «лучше таблеток»
Обещания по питанию	«нормализует сахар», «снизит холестерин», «вылечит кишечник»

4. Безопасные ответы по состояниям

Состояние	Безопасный ответ бота	Действие
Беременность	«При беременности многие процедуры требуют согласования с врачом. Пожалуйста, проконсультируйтесь с врачом.»	risk = warning
Варикоз	«При варикозном расширении вен ряд процедур требует консультации с врачом. Уточните у своего врача.»	risk = medium
Сахарный диабет	«При диабете важно учитывать реакцию кожи и заживление ран. Рекомендую уточнить у эндокринолога.»	risk = medium
Онкология	«Это очень важная информация. Я передам ваш запрос нашему администратору, который свяжется с вами.»	risk = HIGH, handoff
Боль / воспаление	«Если вы сейчас испытываете боль или воспаление, мы не рекомендуем заниматься на тренажерах. Обратитесь к врачу.»	risk = HIGH, handoff
Кожные заболевания	«При кожных заболеваниях в активной фазе большинство процедур противопоказано. Уточните у дерматолога.»	risk = medium
Жалоба / конфликт	«Мне жаль, что у вас возникла эта ситуация. Я немедленно передам ваш запрос нашему администратору.»	risk = HIGH, handoff

5. Safety Layer — архитектура проверок

Safety Layer выполняет 3 последовательных проверки:

Проверка 1 — Pre-LLM (детерминированная)

До вызова LLM. Применяет регулярные выражения и keyword matching к тексту клиента. При обнаружении HIGH-risk паттернов немедленно инициирует handoff без обращения к модели.

Проверка 2 — LLM Context Injection

При risk_level = medium — в системный промпт добавляется Safety Context: «Клиент упомянул [состояние]. Ты обязан: (1) не давать медицинских рекомендаций, (2) использовать только безопасные формулировки из Safety Policy, (3) рекомендовать консультацию с врачом.»

Проверка 3 — Post-LLM Output Guard

После генерации ответа. Сканирует текст на forbidden patterns (см. раздел 3). При нахождении — блокирует ответ и подставляет safety_fallback_template.

6. Nutrition Safety

Nutrition Skill работает с питанием, что создаёт отдельный набор ограничений:

- Бот — wellness-помощник, не диетолог и не нутрициолог
- Все данные о КБЖУ носят ориентировочный характер
- Бот не рекомендует дефицит калорий ниже безопасного уровня
- Бот не даёт лечебных диет при заболеваниях
- Обнаружение паттернов расстройств пищевого поведения → передача администратору
- Данные о питании хранятся только по явному согласию пользователя

7. Escalation Matrix

Триггер	Приоритет	Действие
Упомянута онкология	URGENT	handoff + уведомление старшего администратора
Жалоба на боль / воспаление	HIGH	handoff + уведомление
Конфликт / угрозы	URGENT	handoff + уведомление + лог инцидента
Жалоба на качество услуги	HIGH	handoff + создание задачи admin_task
3+ неудачных попытки ответа	MEDIUM	handoff с контекстом
Клиент явно просит оператора	MEDIUM	немедленный handoff
risk = medium без разрешения	MEDIUM	Safety Context Injection, продолжить с оговорками